Оптимизация пайаплайна Инференса NLP-моделей

Борисов Иван Максимович

2026.03.15

1 Цель работы

Изучение различных уровней оптимизации процесса инференса на примере модели `rubert-mini-frida`. Анализ влияния конвертации в ONNX и внедрения динамического батчирования на RPS и latency.

2 Метрики

Для оценки эффективности были выбраны следующие метрики:

- **Latency (ms)**: время ожидания ответа сервером.
- **RPS**: количество запросов, обрабатываемых системойв секунду.
- **p90/p95 Latency**: устойчивость системы к «выбросам» при нагрузке.

Тестирование проводилось с использованием инструмента `k6` при нагрузке 20 и 100 VUs (Virtual Users) в течение 20 секунд на каждый сценарий.

3 Часть 1: Базовый инференс UVs=100

В качестве базовой линии использовалась модель из библиотеки `transformers`, развернутая через FastAPI.

Система демонстрирует низкую пропускную способность из-за высоких вычислительных затрат transformers-инференса.

- **Avg Latency**: 540.58 мс
- **RPS**: 53.37

4 Часть 2: ONNX UVs=100

Модель была конвертирована в формат ONNX, инференс выполнялся через `onnxruntime`.

Переход на ONNX позволяет оптимизировать граф вычислений.

$$\frac{RPS_{onnx}}{RPS_{simple}} \approx \frac{150.21}{53.37} \approx 2.8x$$

Задержка снизилась более чем в 2.8 раза.

5 Часть 3: Dynamic Batching UVs=100

Для модели ONNX реализован механизм накопления запросов в очередь с последующим объединением в один батч.

Динамическое батчирование позволяет «лучше» утилизировать ресурсы CPU за счет векторизации вычислений, хотя и появляется небольшая задержка на ожидание формирования батча.

При высокой нагрузке (100 VUs) средняя задержка падает за счет уменьшения очереди на обработку.

- **Увеличение RPS**: с 150.21 до 208.62 ($\approx 38.67\%$).
- **Снижение Latency**: avg снизился со 190.31 мс до 136.83 мс.

6 Сводная таблица

Метод	**RPS**	**Avg Latency**	**p90**	**p95**
Base (Transformers)	52.63	108.27 мс	118.20 мс	122.13 мс
ONNX Runtime	149.24	37.99 мс	50.23 мс	57.06 мс
ONNX + Dyn Batch	175.69	32.36 мс	42.97 мс	48.50 мс

Таблица 1: Сравнение производительности при умеренной нагрузке (20 VUs)

Метод	**RPS**	**Avg Latency**	**p90**	**p95**
Base (Transformers)	53.37	540.58 мс	574.64 мс	593.02 мс
ONNX Runtime	150.21	190.31 мс	237.83 мс	277.77 мс
ONNX + Dyn Batch	208.62	136.83 мс	171.60 мс	208.94 мс

Таблица 2: Сравнение производительности при увеличенной нагрузке (100 VUs)

Итого:

- Конвертация модели в формат ONNX позволила увеличить RPS в 2.8 раза и сократить среднюю задержку более чем на 64%
- Внедрение динамического батчирования обеспечило дополнительный прирост RPS на 39% при высокой нагрузке (100 VUs).
- Суммарно оптимизированный пайплайн превзошел базовое решение по производительности почти в 4 раза.

7 Заключение

В ходе тестирования (100 VUs) получены следующие показатели производительности:

Конфигурация	**RPS**	**Avg Latency**	**Ускорение**
Base (Transformers)	53.37	540.58 мс	1.0x
ONNX Runtime	150.21	190.31 мс	2.8x
ONNX + Dyn Batching	208.62	136.83 мс	3.9x

Основные выводы:

- **ONNX Runtime**: обеспечил основной прирост производительности (+181% к RPS).
- **Dynamic Batching**: при высокой нагрузке добавил еще +39% к пропускной способности относительно чистого ONNX, при этом снизив среднюю задержку.
- **Итог**: Оптимизация позволила увеличить пропускную способность системы в **3.9 раза** при четырехкратном снижении задержки.

8 Appendix

Скриншоты нарузки k6:

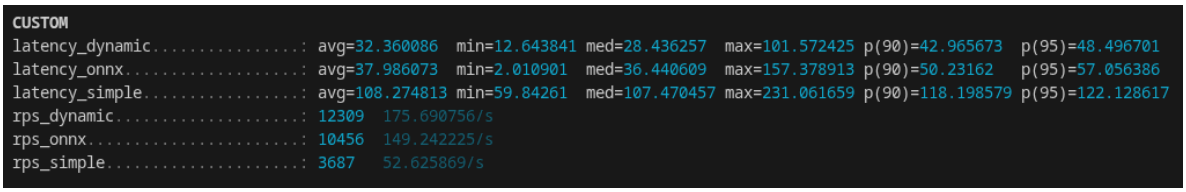

```
CUSTOM
latency_dynamic................: avg=32.360086  min=12.643841 med=28.436257  max=101.572425 p(90)=42.965673  p(95)=48.496701
latency_onnx...................: avg=37.986073  min=2.010901  med=36.440609  max=157.378913 p(90)=50.23162   p(95)=57.056386
latency_simple.................: avg=108.274813 min=59.84261  med=107.470457 max=231.061659 p(90)=118.198579 p(95)=122.128617
rps_dynamic....................: 12309  175.690756/s
rps_onnx.......................: 10456  149.242225/s
rps_simple.....................: 3687   52.625869/s
```

Рис. 1: USv 20

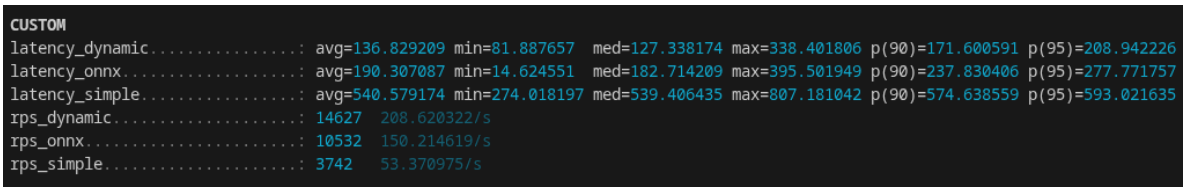

```
CUSTOM
latency_dynamic................: avg=136.829209 min=81.887657  med=127.338174 max=338.401806 p(90)=171.600591 p(95)=208.942226
latency_onnx...................: avg=190.307087 min=14.624551  med=182.714209 max=395.501949 p(90)=237.830406 p(95)=277.771757
latency_simple.................: avg=540.579174 min=274.018197 med=539.406435 max=807.181042 p(90)=574.638559 p(95)=593.021635
rps_dynamic....................: 14627  208.620322/s
rps_onnx.......................: 10532  150.214619/s
rps_simple.....................: 3742   53.370975/s
```

Рис. 2: UVs 100